

Repaso para el examen



Máster en Bioinformática

```
> summary(modelo_logistica)

Call:
glm(formula = death ~ sex + smk, family = "binomial", data = df_complete)

Coefficients:
            Estimate Std. Error z value Pr(>|z|)
(Intercept)   -1.9711     0.6292  -3.133   0.00173 **
sex1          -2.2933     0.7730  -2.967   0.00301 **
smkfumador     1.3978     0.6964   2.007   0.04474 *
smkex-fumador  0.9540     0.7752   1.231   0.21843

---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 127.86  on 147  degrees of freedom
Residual deviance: 103.71  on 144  degrees of freedom
AIC: 111.71

Number of Fisher Scoring iterations: 6

> #### Mostramos únicamente los valores p
> summary(modelo_logistica)$coefficients[, 4]
(Intercept)      sex1      smkfumador smkex-fumador
0.001732784  0.003011526  0.044735481  0.218434752
> |
```

En relación con la variable **sex1** (Estimate = -2.2933; p = 0.0030), ¿cuál es la interpretación más correcta?

- A. El sexo 1 aumenta significativamente la probabilidad de muerte
- B. El sexo 1 no tiene efecto estadísticamente significativo
- C. El sexo 1 reduce significativamente las odds de muerte
- D. El sexo 1 incrementa el riesgo, pero sin significación estadística

```
> summary(modelo_logistica)

Call:
glm(formula = death ~ sex + smk, family = "binomial", data = df_complete)

Coefficients:
            Estimate Std. Error z value Pr(>|z|)
(Intercept)  -1.9711     0.6292  -3.133   0.00173 **
sex1         -2.2933     0.7730  -2.967   0.00301 **
smkfumador    1.3978     0.6964   2.007   0.04474 *
smkex-fumador  0.9540     0.7752   1.231   0.21843
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 127.86  on 147  degrees of freedom
Residual deviance: 103.71  on 144  degrees of freedom
AIC: 111.71

Number of Fisher Scoring iterations: 6

> #### Mostramos únicamente los valores p
> summary(modelo_logistica)$coefficients[, 4]
(Intercept)      sex1      smkfumador smkex-fumador
 0.001732784  0.003011526  0.044735481  0.218434752
> |
```

En relación con la variable **sex1** (Estimate = -2.2933; p = 0.0030), ¿cuál es la interpretación más correcta?

- A. El sexo 1 aumenta significativamente la probabilidad de muerte
- B. El sexo 1 no tiene efecto estadísticamente significativo
- C. El sexo 1 reduce significativamente las odds de muerte
- D. El sexo 1 incrementa el riesgo, pero sin significación estadística

Respuesta correcta: C

El coeficiente es negativo (-2.2933) y estadísticamente significativo ($p = 0.003 < 0.05$). En regresión logística, un coeficiente negativo implica una **reducción en las odds** del evento. El OR sería $\exp(-2.2933) < 1$, indicando efecto protector respecto a la categoría de referencia.

```
> summary(modelo_logistica)

Call:
glm(formula = death ~ sex + smk, family = "binomial", data = df_complete)

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)   -1.9711     0.6292  -3.133  0.00173 **
sex1          -2.2933     0.7730  -2.967  0.00301 **
smkfumador     1.3978     0.6964   2.007  0.04474 *
smkex-fumador  0.9540     0.7752   1.231  0.21843
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 127.86  on 147  degrees of freedom
Residual deviance: 103.71  on 144  degrees of freedom
AIC: 111.71

Number of Fisher Scoring iterations: 6

> #### Mostramos únicamente los valores p
> summary(modelo_logistica)$coefficients[, 4]
(Intercept)      sex1      smkfumador smkex-fumador
0.001732784 0.003011526 0.044735481 0.218434752
> |
```

- ¿Qué indica la diferencia entre la **null deviance** (127.86) y la **residual deviance** (103.71)?
- A. Que el modelo no mejora respecto al modelo nulo
 - B. Que el modelo con predictores mejora el ajuste respecto al modelo sin predictores
 - C. Que existe heterocedasticidad
 - D. Que el modelo presenta sobreajuste

```
> summary(modelo_logistica)

Call:
glm(formula = death ~ sex + smk, family = "binomial", data = df_complete)

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)   -1.9711     0.6292  -3.133   0.00173 **
sex1          -2.2933     0.7730  -2.967   0.00301 **
smkfumador     1.3978     0.6964   2.007   0.04474 *
smkex-fumador  0.9540     0.7752   1.231   0.21843
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 127.86  on 147  degrees of freedom
Residual deviance: 103.71  on 144  degrees of freedom
AIC: 111.71

Number of Fisher Scoring iterations: 6

> #### Mostramos únicamente los valores p
> summary(modelo_logistica)$coefficients[, 4]
(Intercept)      sex1      smkfumador smkex-fumador
0.001732784  0.003011526  0.044735481  0.218434752
>
```

Respuesta correcta: B

La null deviance corresponde al modelo sin predictores (solo intercepto). La reducción hasta 103.71 indica que el modelo con `sex` y `smk` explica parte de la variabilidad en la respuesta. Esta diferencia puede contrastarse mediante un test χ^2 para evaluar mejora global del modelo.

- ¿Qué indica la diferencia entre la **null deviance (127.86)** y la **residual deviance (103.71)**?
- A. Que el modelo no mejora respecto al modelo nulo
 - B. Que el modelo con predictores mejora el ajuste respecto al modelo sin predictores
 - C. Que existe heterocedasticidad
 - D. Que el modelo presenta sobreajuste


```
> summary(mix_models)
Linear mixed-effects model fit by REML
Data: df_complete_long
      AIC      BIC    logLik
3579.139 3627.189 -1778.57

Random effects:
Formula: ~1 | id
      (Intercept) Residual
StdDev:    11.74015  2.923137

Fixed effects: weight ~ age + visit + sex + visit:sex
              Value Std.Error   DF   t-value p-value
(Intercept)  73.97944  4.246841  438  17.419876  0.0000
age           0.11935  0.093555  145   1.275756  0.2041
visit1        0.84416  0.471106  438   1.791859  0.0738
visit2        1.54545  0.471106  438   3.280480  0.0011
visit3        1.24675  0.471106  438   2.646438  0.0084
sex1         -19.25304  2.092476  145  -9.201081  0.0000
visit1:sex1    0.21218  0.680175  438   0.311952  0.7552
visit2:sex1   -0.13700  0.680175  438  -0.201424  0.8405
visit3:sex1    0.06311  0.680175  438   0.092779  0.9261

Correlation:
      (Intr) age    visit1 visit2 visit3 sex1    vst1:1 vst2:1
age      -0.946
visit1   -0.055  0.000
visit2   -0.055  0.000  0.500
visit3   -0.055  0.000  0.500  0.500
sex1     -0.505  0.308  0.113  0.113  0.113
visit1:sex1 0.038  0.000 -0.693 -0.346 -0.346 -0.163
visit2:sex1 0.038  0.000 -0.346 -0.693 -0.346 -0.163  0.500
visit3:sex1 0.038  0.000 -0.346 -0.346 -0.693 -0.163  0.500  0.500

Standardized within-Group Residuals:
      Min      Q1      Med      Q3      Max
-4.27696701 -0.49843657 -0.03494932  0.44406078  3.49766454

Number of observations: 592
Number of Groups: 148
```

En relación con la variable **sex1** ($\beta = -19.25$; $p < 0.001$), ¿cuál es la interpretación más correcta?

- A. El sexo 1 aumenta significativamente el peso medio
- B. El sexo 1 no tiene efecto significativo sobre el peso
- C. El sexo 1 reduce significativamente el peso medio respecto a la categoría de referencia
- D. El efecto del sexo depende significativamente de la visita

```
> summary(mix_models)
Linear mixed-effects model fit by REML
Data: df_complete_long
    AIC      BIC   logLik
3579.139 3627.189 -1778.57

Random effects:
Formula: ~1 | id
      (Intercept) Residual
StdDev:   11.74015  2.923137

Fixed effects: weight ~ age + visit + sex + visit:sex
              Value Std.Error   DF   t-value p-value
(Intercept)  73.97944  4.246841  438  17.419876  0.0000
age           0.11935  0.093555  145   1.275756  0.2041
visit1        0.84416  0.471106  438   1.791859  0.0738
visit2        1.54545  0.471106  438   3.280480  0.0011
visit3        1.24675  0.471106  438   2.646438  0.0084
sex1         -19.25304  2.092476  145  -9.201081  0.0000
visit1:sex1    0.21218  0.680175  438   0.311952  0.7552
visit2:sex1   -0.13700  0.680175  438  -0.201424  0.8405
visit3:sex1    0.06311  0.680175  438   0.092779  0.9261

Correlation:
      (Intr) age   visit1 visit2 visit3 sex1   vst1:1 vst2:1
age      -0.946
visit1   -0.055  0.000
visit2   -0.055  0.000  0.500
visit3   -0.055  0.000  0.500  0.500
sex1     -0.505  0.308  0.113  0.113  0.113
visit1:sex1 0.038  0.000 -0.693 -0.346 -0.346 -0.163
visit2:sex1 0.038  0.000 -0.346 -0.693 -0.346 -0.163  0.500
visit3:sex1 0.038  0.000 -0.346 -0.346 -0.693 -0.163  0.500  0.500

Standardized Within-Group Residuals:
      Min       Q1       Med       Q3       Max
-4.27696701 -0.49843657 -0.03494932  0.44406078  3.49766454

Number of observations: 592
Number of Groups: 148
```

En relación con la variable **sex1** ($\beta = -19.25$; $p < 0.001$), ¿cuál es la interpretación más correcta?

- A. El sexo 1 aumenta significativamente el peso medio
- B. El sexo 1 no tiene efecto significativo sobre el peso
- C. El sexo 1 reduce significativamente el peso medio respecto a la categoría de referencia
- D. El efecto del sexo depende significativamente de la visita

Respuesta correcta: C

El coeficiente es negativo (-19.25) y altamente significativo ($p < 0.001$). Esto indica que, en promedio y manteniendo constantes las demás variables, el grupo **sex1** tiene aproximadamente 19 unidades menos de peso que la categoría de referencia. Es un efecto principal fuerte e independiente.

```
> summary(mix_models)
Linear mixed-effects model fit by REML
Data: df_complete_long
      AIC      BIC    logLik
3579.139 3627.189 -1778.57

Random effects:
Formula: ~1 | id
      (Intercept) Residual
StdDev:   11.74015  2.923137

Fixed effects: weight ~ age + visit + sex + visit:sex
              Value Std.Error   DF   t-value p-value
(Intercept)  73.97944  4.246841  438  17.419876  0.0000
age           0.11935  0.093555  145   1.275756  0.2041
visit1        0.84416  0.471106  438   1.791859  0.0738
visit2        1.54545  0.471106  438   3.280480  0.0011
visit3        1.24675  0.471106  438   2.646438  0.0084
sex1         -19.25304  2.092476  145  -9.201081  0.0000
visit1:sex1    0.21218  0.680175  438   0.311952  0.7552
visit2:sex1   -0.13700  0.680175  438  -0.201424  0.8405
visit3:sex1    0.06311  0.680175  438   0.092779  0.9261

Correlation:
      (Intr) age    visit1 visit2 visit3 sex1   vst1:1 vst2:1
age      -0.946
visit1   -0.055  0.000
visit2   -0.055  0.000  0.500
visit3   -0.055  0.000  0.500  0.500
sex1     -0.505  0.308  0.113  0.113  0.113
visit1:sex1 0.038  0.000 -0.693 -0.346 -0.346 -0.163
visit2:sex1 0.038  0.000 -0.346 -0.693 -0.346 -0.163  0.500
visit3:sex1 0.038  0.000 -0.346 -0.346 -0.693 -0.163  0.500  0.500

Standardized within-Group Residuals:
      Min      Q1      Med      Q3      Max
-4.27696701 -0.49843657 -0.03494932  0.44406078  3.49766454

Number of observations: 592
Number of Groups: 148
```

Considerando los términos de interacción visit:sex (todos con $p > 0.75$), ¿cuál es la conclusión más adecuada?

- A. El efecto del sexo cambia significativamente según la visita
- B. No hay evidencia de que el efecto del sexo varíe entre visitas
- C. Las visitas no tienen efecto sobre el peso
- D. El modelo está mal especificado


```
> summary(mix_models)
Linear mixed-effects model fit by REML
Data: df_complete_long
      AIC      BIC    logLik
3579.139 3627.189 -1778.57

Random effects:
Formula: ~1 | id
      (Intercept) Residual
StdDev:    11.74015  2.923137

Fixed effects: weight ~ age + visit + sex + visit:sex
              Value Std.Error   DF   t-value p-value
(Intercept)  73.97944  4.246841  438  17.419876  0.0000
age           0.11935  0.093555  145   1.275756  0.2041
visit1        0.84416  0.471106  438   1.791859  0.0738
visit2        1.54545  0.471106  438   3.280480  0.0011
visit3        1.24675  0.471106  438   2.646438  0.0084
sex1         -19.25304  2.092476  145  -9.201081  0.0000
visit1:sex1    0.21218  0.680175  438   0.311952  0.7552
visit2:sex1   -0.13700  0.680175  438  -0.201424  0.8405
visit3:sex1    0.06311  0.680175  438   0.092779  0.9261

Correlation:
      (Intr) age    visit1 visit2 visit3 sex1    vst1:1 vst2:1
age      -0.946
visit1   -0.055  0.000
visit2   -0.055  0.000  0.500
visit3   -0.055  0.000  0.500  0.500
sex1     -0.505  0.308  0.113  0.113  0.113
visit1:sex1 0.038  0.000 -0.693 -0.346 -0.346 -0.163
visit2:sex1 0.038  0.000 -0.346 -0.693 -0.346 -0.163  0.500
visit3:sex1 0.038  0.000 -0.346 -0.346 -0.693 -0.163  0.500  0.500

Standardized within-Group Residuals:
      Min      Q1      Med      Q3      Max
-4.27696701 -0.49843657 -0.03494932  0.44406078  3.49766454

Number of observations: 592
Number of Groups: 148
```

Considerando los términos de interacción visit:sex (todos con $p > 0.75$), ¿cuál es la conclusión más adecuada?

- A. El efecto del sexo cambia significativamente según la visita
- B. No hay evidencia de que el efecto del sexo varíe entre visitas
- C. Las visitas no tienen efecto sobre el peso
- D. El modelo está mal especificado

Respuesta correcta: B

Los términos visit1:sex1, visit2:sex1 y visit3:sex1 no son estadísticamente significativos ($p > 0.05$). Esto indica que no hay evidencia suficiente para afirmar que la evolución del peso a lo largo de las visitas sea diferente según el sexo. El efecto del sexo es estable en el tiempo.

```
> summary(modelo_logistica)

Call:
glm(formula = death ~ sex + smk, family = "binomial", data = df_complete)

Coefficients:
            Estimate Std. Error z value Pr(>|z|)
(Intercept)  -1.9711     0.6292  -3.133  0.00173 **
sex1         -2.2933     0.7730  -2.967  0.00301 **
smk1          1.3978     0.6964   2.007  0.04474 *
smk2          0.9540     0.7752   1.231  0.21843
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 127.86  on 147  degrees of freedom
Residual deviance: 103.71  on 144  degrees of freedom
AIC: 111.71

Number of Fisher Scoring iterations: 6

> #### Intervalos de confianza de los coeficientes (escala logit)
> confint(modelo_logistica)

waiting for profiling to be done...

            2.5 %      97.5 %
(Intercept) -3.4321639 -0.8786653
sex1        -4.1670133 -0.9788514
smk1         0.1334376  2.9501965
smk2        -0.5199837  2.6147329
> #### Cálculo de Odds Ratios (OR)
> exp(modelo_logistica$coefficients)
            sex1      smk1      smk2
(Intercept) 0.1393015 0.1009346 4.0463890 2.5960840
> exp(coef(modelo_logistica))
(Intercept)  sex1      smk1      smk2
0.1393015 0.1009346 4.0463890 2.5960840
> #### Intervalos de confianza de las OR
> exp(confint(modelo_logistica))

waiting for profiling to be done...

            2.5 %      97.5 %
(Intercept) 0.03231694 0.4153369
sex1        0.01549848 0.3757424
smk1        1.14274998 19.1097086
smk2        0.59453022 13.6635667
>
```

Considerando que para **smk1** se obtiene:

- OR = 4.04
- IC95%: (1.14 – 19.11)
- p = 0.044

¿Cuál es la interpretación más correcta?

- A. smk1 no tiene efecto sobre la probabilidad de muerte
- B. smk1 cuadruplica aproximadamente las odds de muerte y el efecto es estadísticamente significativo
- C. smk1 reduce el riesgo de muerte
- D. smk1 es significativo solo en escala logit, pero no en OR

```
> summary(modelo_logistica)

Call:
glm(formula = death ~ sex + smk, family = "binomial", data = df_complete)

Coefficients:
            Estimate Std. Error z value Pr(>|z|)
(Intercept)  -1.9711     0.6292  -3.133  0.00173 **
sex1         -2.2933     0.7730  -2.967  0.00301 **
smk1          1.3978     0.6964   2.007  0.04474 *
smk2          0.9540     0.7752   1.231  0.21843
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 127.86  on 147  degrees of freedom
Residual deviance: 103.71  on 144  degrees of freedom
AIC: 111.71

Number of Fisher Scoring iterations: 6

> #### Intervalos de confianza de los coeficientes (escala logit)
> confint(modelo_logistica)

waiting for profiling to be done...

            2.5 %      97.5 %
(Intercept) -3.4321639 -0.8786653
sex1        -4.1670133 -0.9788514
smk1         0.1334376  2.9501965
smk2        -0.5199837  2.6147329
> #### cálculo de Odds Ratios (OR)
> exp(modelo_logistica$coefficients)
            sex1      smk1      smk2
(Intercept) 0.1393015 0.1009346 4.0463890 2.5960840
> exp(coef(modelo_logistica))
(Intercept)  sex1      smk1      smk2
0.1393015 0.1009346 4.0463890 2.5960840
> #### Intervalos de confianza de las OR
> exp(confint(modelo_logistica))

waiting for profiling to be done...

            2.5 %      97.5 %
(Intercept) 0.03231694 0.4153369
sex1        0.01549848 0.3757424
smk1        1.14274998 19.1097086
smk2        0.59453022 13.6635667
```

Considerando que para **smk1** se obtiene:

- OR = 4.04
- IC95%: (1.14 – 19.11)
- p = 0.044

¿Cuál es la interpretación más correcta?

- A. smk1 no tiene efecto sobre la probabilidad de muerte
- B. smk1 cuadruplica aproximadamente las odds de muerte y el efecto es estadísticamente significativo
- C. smk1 reduce el riesgo de muerte
- D. smk1 es significativo solo en escala logit, pero no en OR

Respuesta correcta: B

El OR = 4.04 indica que las odds del evento son aproximadamente cuatro veces mayores en el grupo smk1 respecto a la categoría de referencia. El IC95% no incluye 1 (1.14–19.11), por lo que el efecto es estadísticamente significativo. El intervalo es amplio, lo que sugiere cierta imprecisión.

```
> summary(modelo_logistica)

Call:
glm(formula = death ~ sex + smk, family = "binomial", data = df_complete)

Coefficients:
            Estimate Std. Error z value Pr(>|z|)
(Intercept)  -1.9711     0.6292  -3.133  0.00173 **
sex1         -2.2933     0.7730  -2.967  0.00301 **
smk1          1.3978     0.6964   2.007  0.04474 *
smk2          0.9540     0.7752   1.231  0.21843
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 127.86  on 147  degrees of freedom
Residual deviance: 103.71  on 144  degrees of freedom
AIC: 111.71

Number of Fisher Scoring iterations: 6

> #### Intervalos de confianza de los coeficientes (escala logit)
> confint(modelo_logistica)

waiting for profiling to be done...

              2.5 %      97.5 %
(Intercept) -3.4321639 -0.8786653
sex1        -4.1670133 -0.9788514
smk1         0.1334376  2.9501965
smk2        -0.5199837  2.6147329
> #### Cálculo de Odds Ratios (OR)
> exp(modelo_logistica$coefficients)
(Intercept)      sex1      smk1      smk2
0.1393015  0.1009346  4.0463890  2.5960840
> exp(coef(modelo_logistica))
(Intercept)      sex1      smk1      smk2
0.1393015  0.1009346  4.0463890  2.5960840
> #### Intervalos de confianza de las OR
> exp(confint(modelo_logistica))

waiting for profiling to be done...

              2.5 %      97.5 %
(Intercept) 0.03231694 0.4153369
sex1        0.01549848 0.3757424
smk1        1.14274998 19.1097086
smk2        0.59453022 13.6635667
```

Para **sex1** se obtiene:

OR = 0.10

IC95%: (0.015 – 0.376)

p = 0.003

¿Cuál es la interpretación correcta?

A. sex1 aumenta el riesgo de muerte

B. sex1 reduce significativamente las odds de muerte respecto a la referencia

C. sex1 no es estadísticamente significativo

D. sex1 tiene un efecto clínicamente irrelevante


```
> summary(modelo_logistica)

Call:
glm(formula = death ~ sex + smk, family = "binomial", data = df_complete)

Coefficients:
            Estimate Std. Error z value Pr(>|z|)
(Intercept)  -1.9711     0.6292  -3.133  0.00173 **
sex1         -2.2933     0.7730  -2.967  0.00301 **
smk1          1.3978     0.6964   2.007  0.04474 *
smk2          0.9540     0.7752   1.231  0.21843
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 127.86  on 147  degrees of freedom
Residual deviance: 103.71  on 144  degrees of freedom
AIC: 111.71

Number of Fisher Scoring iterations: 6

> #### Intervalos de confianza de los coeficientes (escala logit)
> confint(modelo_logistica)

waiting for profiling to be done...

            2.5 %      97.5 %
(Intercept) -3.4321639 -0.8786653
sex1        -4.1670133 -0.9788514
smk1         0.1334376  2.9501965
smk2        -0.5199837  2.6147329
> #### cálculo de Odds Ratios (OR)
> exp(modelo_logistica$coefficients)
(Intercept)      sex1      smk1      smk2
0.1393015  0.1009346  4.0463890  2.5960840
> exp(coef(modelo_logistica))
(Intercept)      sex1      smk1      smk2
0.1393015  0.1009346  4.0463890  2.5960840
> #### Intervalos de confianza de las OR
> exp(confint(modelo_logistica))

waiting for profiling to be done...

            2.5 %      97.5 %
(Intercept) 0.03231694 0.4153369
sex1        0.01549848 0.3757424
smk1        1.14274998 19.1097086
smk2        0.59453022 13.6635667
```

Para **sex1** se obtiene:

OR = 0.10

IC95%: (0.015 – 0.376)

p = 0.003

¿Cuál es la interpretación correcta?

- A. sex1 aumenta el riesgo de muerte
- B. sex1 reduce significativamente las odds de muerte respecto a la referencia
- C. sex1 no es estadísticamente significativo
- D. sex1 tiene un efecto clínicamente irrelevante

Respuesta correcta: B

El OR = 0.10 indica una reducción del 90% aproximadamente en las odds del evento respecto a la categoría de referencia. El intervalo de confianza no incluye 1 y el p-valor es < 0.01, por lo que el efecto es estadísticamente significativo y consistente.

```
> summary(regress_multiple)

Call:
lm(formula = age ~ weight0 + sex + smk, data = df_complete)

Residuals:
    Min       1Q   Median       3Q      Max
-17.843  -7.805  -2.200   7.585  27.527

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  32.94771    5.72751   5.753 0.0000000514 ***
weight0      0.10906    0.07002   1.557   0.12158
sexfemale   -4.19955    2.22644  -1.886   0.06129 .
smkformer   -0.61110    1.98219  -0.308   0.75830
smkcurrent    6.03644    2.26364   2.667   0.00854 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 10.15 on 143 degrees of freedom
Multiple R-squared:  0.1702,    Adjusted R-squared:  0.147
F-statistic: 7.334 on 4 and 143 DF,  p-value: 0.00002116
```

Considerando que el coeficiente de **smkcurrent** es 6.04 ($p = 0.0085$), ¿cuál es la interpretación correcta?

- A. Los fumadores actuales tienen en promedio 6 años menos que la categoría de referencia
- B. Los fumadores actuales tienen en promedio 6 años más que la categoría de referencia, ajustando por el resto de variables
- C. Fumar actualmente no tiene efecto significativo sobre la edad
- D. El efecto de fumar depende del sexo

```
> summary(regress_multiple)

Call:
lm(formula = age ~ weight0 + sex + smk, data = df_complete)

Residuals:
    Min       1Q   Median       3Q      Max
-17.843  -7.805  -2.200   7.585  27.527

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  32.94771    5.72751   5.753 0.0000000514 ***
weight0      0.10906    0.07002   1.557   0.12158
sexfemale   -4.19955    2.22644  -1.886   0.06129 .
smkformer   -0.61110    1.98219  -0.308   0.75830
smkcurrent    6.03644    2.26364   2.667   0.00854 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 10.15 on 143 degrees of freedom
Multiple R-squared:  0.1702,    Adjusted R-squared:  0.147
F-statistic: 7.334 on 4 and 143 DF,  p-value: 0.00002116
```

Respuesta correcta: B

El coeficiente positivo (6.04) indica que, manteniendo constantes peso inicial y sexo, los fumadores actuales tienen en promedio aproximadamente 6 años más que la categoría de referencia (probablemente no fumadores). El p-valor < 0.01 indica que el efecto es estadísticamente significativo.

Considerando que el coeficiente de **smkcurrent** es 6.04 ($p = 0.0085$), ¿cuál es la interpretación correcta?

- A. Los fumadores actuales tienen en promedio 6 años menos que la categoría de referencia
- B. Los fumadores actuales tienen en promedio 6 años más que la categoría de referencia, ajustando por el resto de variables
- C. Fumar actualmente no tiene efecto significativo sobre la edad
- D. El efecto de fumar depende del sexo

```
> summary(regress_multiple)

Call:
lm(formula = age ~ weight0 + sex + smk, data = df_complete)

Residuals:
    Min       1Q   Median       3Q      Max
-17.843  -7.805  -2.200   7.585  27.527

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  32.94771    5.72751   5.753 0.0000000514 ***
weight0      0.10906    0.07002   1.557   0.12158
sexfemale   -4.19955    2.22644  -1.886   0.06129 .
smkformer   -0.61110    1.98219  -0.308   0.75830
smkcurrent    6.03644    2.26364   2.667   0.00854 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 10.15 on 143 degrees of freedom
Multiple R-squared:  0.1702,    Adjusted R-squared:  0.147
F-statistic: 7.334 on 4 and 143 DF,  p-value: 0.00002116
```

El modelo presenta un R^2 ajustado = 0.147 y un p-valor global del modelo < 0.001 . ¿Cuál es la conclusión más adecuada?

- A. El modelo explica aproximadamente el 14.7% de la variabilidad de la edad y es globalmente significativo
- B. El modelo tiene un ajuste excelente
- C. Todas las variables del modelo son estadísticamente significativas
- D. El modelo no mejora respecto al modelo nulo


```
> summary(regress_multiple)

Call:
lm(formula = age ~ weight0 + sex + smk, data = df_complete)

Residuals:
    Min       1Q   Median       3Q      Max
-17.843  -7.805  -2.200   7.585  27.527

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  32.94771    5.72751   5.753 0.0000000514 ***
weight0      0.10906    0.07002   1.557   0.12158
sexfemale   -4.19955    2.22644  -1.886   0.06129 .
smkformer   -0.61110    1.98219  -0.308   0.75830
smkcurrent    6.03644    2.26364   2.667   0.00854 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 10.15 on 143 degrees of freedom
Multiple R-squared:  0.1702,    Adjusted R-squared:  0.147
F-statistic: 7.334 on 4 and 143 DF,  p-value: 0.00002116
```

Respuesta correcta: A

El R^2 ajustado indica que el modelo explica un 14.7% de la variabilidad en la edad. El test F global ($p < 0.001$) indica que al menos una de las variables predictoras contribuye significativamente al modelo. Sin embargo, el ajuste es moderado, no alto.


El modelo presenta un R^2 ajustado = 0.147 y un p-valor global del modelo < 0.001 . ¿Cuál es la conclusión más adecuada?

- A. El modelo explica aproximadamente el 14.7% de la variabilidad de la edad y es globalmente significativo
- B. El modelo tiene un ajuste excelente
- C. Todas las variables del modelo son estadísticamente significativas
- D. El modelo no mejora respecto al modelo nulo



Observando la orientación de las variables, ¿cuál de las siguientes afirmaciones es correcta?

- A. X100m y Long.jump están fuertemente correlacionadas positivamente
- B. X100m y X110m.hurdle muestran una fuerte correlación positiva
- C. Pole.vault y High.jump están fuertemente correlacionadas negativamente
- D. Discus y X400m están altamente correlacionadas




Observando la orientación de las variables, ¿cuál de las siguientes afirmaciones es correcta?

- A. X100m y Long.jump están fuertemente correlacionadas positivamente
- B. X100m y X110m.hurdle muestran una fuerte correlación positiva
- C. Pole.vault y High.jump están fuertemente correlacionadas negativamente
- D. Discus y X400m están altamente correlacionadas


Respuesta correcta: B

X100m y X110m.hurdle aparecen prácticamente en la misma dirección (ángulo pequeño entre vectores), lo que indica **alta correlación positiva**. En un círculo de correlaciones, el ángulo entre vectores aproxima la correlación (coseno del ángulo).



¿Qué representa principalmente la Dimensión 1 (41.2%) en este gráfico?

- A. Una dimensión dominada por pruebas de velocidad frente a pruebas de salto/lanzamiento
- B. Una dimensión asociada exclusivamente al salto con pértiga
- C. Una dimensión sin interpretación clara
- D. Una dimensión dominada únicamente por High.jump




¿Qué representa principalmente la Dimensión 1 (41.2%) en este gráfico?

- A. Una dimensión dominada por pruebas de velocidad frente a pruebas de salto/lanzamiento
- B. Una dimensión asociada exclusivamente al salto con pértiga
- C. Una dimensión sin interpretación clara
- D. Una dimensión dominada únicamente por High.jump


Respuesta correcta: A

En Dim1, las pruebas de velocidad (X100m, X110m.hurdle, X400m) se sitúan hacia valores negativos, mientras que pruebas de salto y lanzamiento (Long.jump, Shot.put, Discus, High.jump) se sitúan hacia valores positivos. Esto sugiere que la primera componente separa rendimiento en pruebas de velocidad frente a pruebas técnicas/de fuerza.



Observando la intensidad del color ($\cos^2$), ¿cuál de las siguientes variables está mejor representada en el plano Dim1–Dim2?

- A. Javelin
- B. X1500m
- C. X100m
- D. Discus




Observando la intensidad del color ($\cos^2$), ¿cuál de las siguientes variables está mejor representada en el plano Dim1-Dim2?

- A. Javelin
- B. X1500m
- C. X100m
- D. Discus


Respuesta correcta: C

X100m aparece con color más intenso ($\cos^2$ alto, cercano a 0.7–0.8), lo que indica que una gran proporción de su varianza está explicada por las dos primeras componentes. Cuanto más intenso el color y más próximo al círculo, mejor representación.



¿Qué puede concluirse sobre la relación entre **High.jump** y **X100m**?

- A. Están fuertemente correlacionadas positivamente
- B. Están aproximadamente no correlacionadas
- C. Están correlacionadas negativamente
- D. No se puede inferir relación alguna




¿Qué puede concluirse sobre la relación entre **High.jump** y **X100m**?

- A. Están fuertemente correlacionadas positivamente
- B. Están aproximadamente no correlacionadas
- C. Están correlacionadas negativamente
- D. No se puede inferir relación alguna


Respuesta correcta: C

High.jump apunta hacia el cuadrante positivo de Dim1 y negativo de Dim2, mientras que X100m apunta hacia Dim1 negativo. El ángulo entre los vectores es cercano a 180° respecto a la dimensión principal, lo que indica **correlación negativa**.



En el gráfico, los puntos rojos situados a la derecha representan:

- A. Genes con logFC negativo y no significativos
- B. Genes sobreexpresados con significación estadística
- C. Genes infraexpresados con alta significación
- D. Genes con p-valor alto




En el gráfico, los puntos rojos situados a la derecha representan:

- A. Genes con logFC negativo y no significativos
- B. Genes sobreexpresados con significación estadística
- C. Genes infraexpresados con alta significación
- D. Genes con p-valor alto

Respuesta correcta: B


En un volcano plot, el eje X representa el log fold change (logFC). Valores positivos (derecha) indican **sobreexpresión** en el grupo comparado. El eje Y es $-\log_{10}(p)$, por lo que valores altos indican mayor significación estadística. Los puntos rojos combinan ambos criterios.



¿Qué puede concluirse sobre el gen **Rbp1**?

- A. Está infraexpresado y es no significativo
- B. Presenta alta sobreexpresión y es estadísticamente significativo
- C. Está cerca de $\log FC = 0$, por lo que no tiene efecto biológico
- D. Es significativo pero con logFC negativo

● Down
● Not Sig
● Up




¿Qué puede concluirse sobre el gen **Rbp1**?

- A. Está infraexpresado y es no significativo
- B. Presenta alta sobreexpresión y es estadísticamente significativo
- C. Está cerca de $\log\text{FC} = 0$, por lo que no tiene efecto biológico
- D. Es significativo pero con $\log\text{FC}$ negativo

● Down
● Not Sig
● Up


Respuesta correcta: B

Rbp1 aparece en el extremo derecho del gráfico ($\log\text{FC}$ positivo alto) y con valor elevado en el eje Y ($-\log_{10}(\text{p})$ alto), lo que indica fuerte sobreexpresión y alta significación estadística.



Observando el dendrograma superior (columnas), ¿qué puede concluirse sobre las variables `mpg` y `wt`?

- A. Están en ramas separadas, por lo que no están relacionadas
- B. Se agrupan en el mismo clúster, indicando comportamiento similar
- C. Muestran correlación positiva fuerte
- D. No contribuyen al clustering




Observando el dendrograma superior (columnas), ¿qué puede concluirse sobre las variables `mpg` y `wt`?

- A. Están en ramas separadas, por lo que no están relacionadas
- B. Se agrupan en el mismo clúster, indicando comportamiento similar
- C. Muestran correlación positiva fuerte
- D. No contribuyen al clustering


Respuesta correcta: B

En el dendrograma superior, `mpg` y `wt` aparecen próximas dentro del mismo clúster, lo que indica que presentan un patrón similar a lo largo de los coches. El clustering agrupa variables con perfiles parecidos.



En el heatmap se observan dos grandes bloques de coches: uno con valores altos en disp, hp y wt, y otro con valores bajos en esas variables. ¿Qué indica esto?

- A. Que los coches están agrupados según su potencia y tamaño
- B. Que el clustering es aleatorio
- C. Que las variables no influyen en la agrupación
- D. Que el método de clustering no es adecuado




En el heatmap se observan dos grandes bloques de coches: uno con valores altos en disp, hp y wt, y otro con valores bajos en esas variables. ¿Qué indica esto?

- A. Que los coches están agrupados según su potencia y tamaño
- B. Que el clustering es aleatorio
- C. Que las variables no influyen en la agrupación
- D. Que el método de clustering no es adecuado

Respuesta correcta: A


Los colores cálidos (rojo) en `disp`, `hp` y `wt` indican coches con mayor cilindrada, potencia y peso, que tienden a agruparse juntos. El clustering jerárquico detecta esta estructura y separa coches grandes/potentes de coches pequeños/ligeros.



A = 2 (1.75 a 2.25)
B = 1.5 (0.9 a 2.2)
C = 2 (1.25 a 2.8)
D = 1.5 (1.25 a 1.75)
E = 1 (0.75 a 1.25)
F = 0.25 (0.01 a 0.75)
G = 0.5 (0.15 a 1.25)
H = 1.5 (0.30 a 3.30)

¿Cuál de las siguientes variables muestra una asociación estadísticamente significativa **protectora** (OR < 1 y el IC no incluye 1)?

- A. E
- B. F
- C. G
- D. H




¿Cuál de las siguientes variables muestra una asociación estadísticamente significativa **protectora** (OR < 1 y el IC no incluye 1)?

- A. E
- B. F
- C. G
- D. H

Respuesta correcta: B

F = 0.25 (0.01 a 0.75). El OR es menor que 1 y el intervalo de confianza no incluye el valor nulo (1), por lo que la asociación es estadísticamente significativa y protectora.




¿Cuál de las siguientes variables presenta una asociación estadísticamente significativa de riesgo (OR > 1 y el IC no incluye 1)?

- A. B
- B. C
- C. E
- D. H

Respuesta correcta: B


C = 2 (1.25 a 2.8). El intervalo de confianza está completamente por encima de 1, lo que indica asociación significativa y aumento del riesgo. B y H incluyen el 1 en su intervalo, por lo que no son significativas.



- ¿Qué ocurre con los coeficientes a medida que aumenta el valor de λ (hacia la derecha del gráfico)?
- A. Aumentan en magnitud
 - B. Permanecen constantes
 - C. Se aproximan progresivamente a 0
 - D. Cambian de signo sistemáticamente


Respuesta correcta: C

En LASSO, al aumentar λ aumenta la penalización L1. Esto provoca que los coeficientes se reduzcan en magnitud y muchos se vuelvan exactamente 0, realizando selección automática de variables.



En la parte superior del gráfico aparecen números (7, 5, 3, 2, 1). ¿Qué representan?

- A. El número de iteraciones del algoritmo
- B. El número de observaciones
- C. El número de variables con coeficientes distintos de cero
- D. El valor del AIC




En la parte superior del gráfico aparecen números (7, 5, 3, 2, 1). ¿Qué representan?

- A. El número de iteraciones del algoritmo
- B. El número de observaciones
- C. El número de variables con coeficientes distintos de cero
- D. El valor del AIC


Respuesta correcta: C

En los gráficos de `glmnet`, los números superiores indican el número de coeficientes activos (distintos de cero) para cada valor de λ . A medida que λ aumenta, el número de variables seleccionadas disminuye.



Observando la curva, ¿qué modelo muestra mejor rendimiento global en términos de equilibrio entre precisión y recall?

- A. BERT
- B. DistilBERT
- C. MultiModal
- D. XGB_DistilBERT




Observando la curva, ¿qué modelo muestra mejor rendimiento global en términos de equilibrio entre precisión y recall?

- A. BERT
- B. DistilBERT
- C. MultiModal
- D. XGB_DistilBERT


Respuesta correcta: D

La curva azul (XGB_DistilBERT) se mantiene por encima de las demás durante la mayor parte del rango de recall, lo que indica mayor precisión para valores similares de recall. En curvas PR, cuanto más cerca de la esquina superior derecha, mejor rendimiento.



Si el objetivo es maximizar la **precisión** cuando el **recall** es alto (≈ 0.8), ¿qué modelo sería más adecuado?

- A. MultiModal
- B. DistilBERT
- C. XGB_DistilBERT
- D. Todos tienen rendimiento equivalente



Si el objetivo es maximizar la **precisión** cuando el **recall** es alto (≈ 0.8), ¿qué modelo sería más adecuado?

- A. MultiModal
- B. DistilBERT
- C. XGB_DistilBERT
- D. Todos tienen rendimiento equivalente

Respuesta correcta: C

Explicación:

En valores altos de recall (~ 0.8), la curva azul (XGB_DistilBERT) mantiene mayor precisión comparada con los otros modelos. Esto indica mejor capacidad para mantener pocos falsos positivos incluso cuando se capturan muchos verdaderos positivos.

¡Muchas gracias!

¿Preguntas?

